




Tiếng Việt RAG Chatbot: Từ Dữ liệu Thô đến AI Sinh ngữ cảnh

Kết hợp Machine Learning truyền thống, PhoBERT, FAISS
và Ollama trong kiến trúc Retrieval-Augmented Generation.

Tác giả: Phan Trọng Nguyên

Tổng quan Hệ thống RAG End-to-End

Phân loại & Xử lý

Tích hợp Machine Learning truyền thống (TF-IDF) và Transformer (PhoBERT).

Mục đích: Phân loại tin tức tiếng Việt chính xác.

Truy xuất Ngữ nghĩa

Sử dụng cơ sở dữ liệu vector FAISS.


Mục đích: Tìm kiếm và trích xuất các tài liệu liên quan nhất theo ngữ cảnh.

Sinh Văn bản

Suy luận LLM cục bộ thông qua Ollama.


Mục đích: Trả lời câu hỏi của người dùng dựa trên context đã truy xuất.

Động cơ RAG Luồng kép



Cấu trúc Dữ liệu: Phân loại Tin tức Tiếng Việt


```
PH0_BERTS/data/processed/raw/du_lich/  
PH0_BERTS/data/processed/raw/kinh_te/  
PH0_BERTS/data/processed/raw/phap_luat/  
PH0_BERTS/data/processed/raw/tam_su/  
PH0_BERTS/data/processed/raw/the_gioi/  
PH0_BERTS/data/processed/raw/the_thao/  
PH0_BERTS/data/processed/raw/thi_truong/  
PH0_BERTS/data/processed/raw/thoi_su/  
PH0_BERTS/data/processed/raw/truyen_hinh/  
PH0_BERTS/data/processed/raw/van_hoa/  
PH0_BERTS/data/processed/raw/xa_hoi/  
PH0_BERTS/data/processed/raw/y_kien/  
PH0_BERTS/data/processed/raw/y_te/  
PH0_BERTS/data/processed/raw/README.md
```



Phân mảnh dữ liệu thành 13 chuyên mục tin tức cốt lõi để thiết lập ranh giới ngữ nghĩa cho mô hình phân loại.

Đường ống Tiền xử lý Dữ liệu

```
<div class='content'>
...&/&l({t^&hata;}~
&nbsp;http://exampl
e.com#ref ...=..g
+<?{&f, 16&nbsp;}/
<UOT % [16TH!$ OC\>
tên lửa...🚀
\r\n\r\n
```



Giai đoạn 1: Thiết lập Mô hình Cơ sở (Baselines)

Trích xuất Đặc trưng

Phương pháp: TF-IDF Vectorizer

Thông số kỹ thuật:

`max_features = 5000`

`ngram_range = (1,2)`

Thuật toán Học máy

1. Logistic Regression

2. Support Vector Machine (SVM)

3. Multinomial Naive Bayes

Mục tiêu: Tạo thước đo hiệu suất đáng tin cậy bằng phương pháp đếm từ vựng truyền thống trước khi áp dụng Deep Learning.

Giai đoạn 2: Nâng cấp với Kiến trúc PhoBERT

Thông số Mô hình

Core: `vinai/phobert-base`

Huấn luyện: HuggingFace Trainer

Đường ống Xử lý (Processing)


Chia tập dữ liệu: Train / Validation / Test

Tokenization: `max_length = 256`


Xử lý chuỗi: Padding & truncation

Chỉ số Đánh giá

Accuracy, Precision, Recall, F1-score



Đánh giá Hiệu năng: Các Mô hình Cơ sở



Nhận xét: SVM cung cấp một nền tảng vững chắc, vượt trội rõ rệt so với các thuật toán thống kê cơ bản.

Kết quả PhoBERT: Đột phá Ngữ nghĩa



Độ chính xác (Accuracy)



Macro F1



Weighted F1

Đột phá: Transformer model xử lý ngữ cảnh tốt hơn đáng kể so với phương pháp đếm từ vựng truyền thống (TF-IDF), đẩy giới hạn hiệu năng lên mức tối đa trong thí nghiệm.

Trận chiến Thuật toán: SVM vs. PhoBERT

Tiêu chí	SVM	PhoBERT
Phương pháp Trích xuất	TF-IDF (Tần suất từ)	Contextual Embeddings
Nhận thức Ngữ cảnh	Yếu	Xuất sắc
F1-score	0.86	0.89
Accuracy	0.86	0.89

Kết luận: PhoBERT out-performs tất cả các mô hình cơ sở, khẳng định sức mạnh của Transformers trong xử lý ngôn ngữ tự nhiên Tiếng Việt.

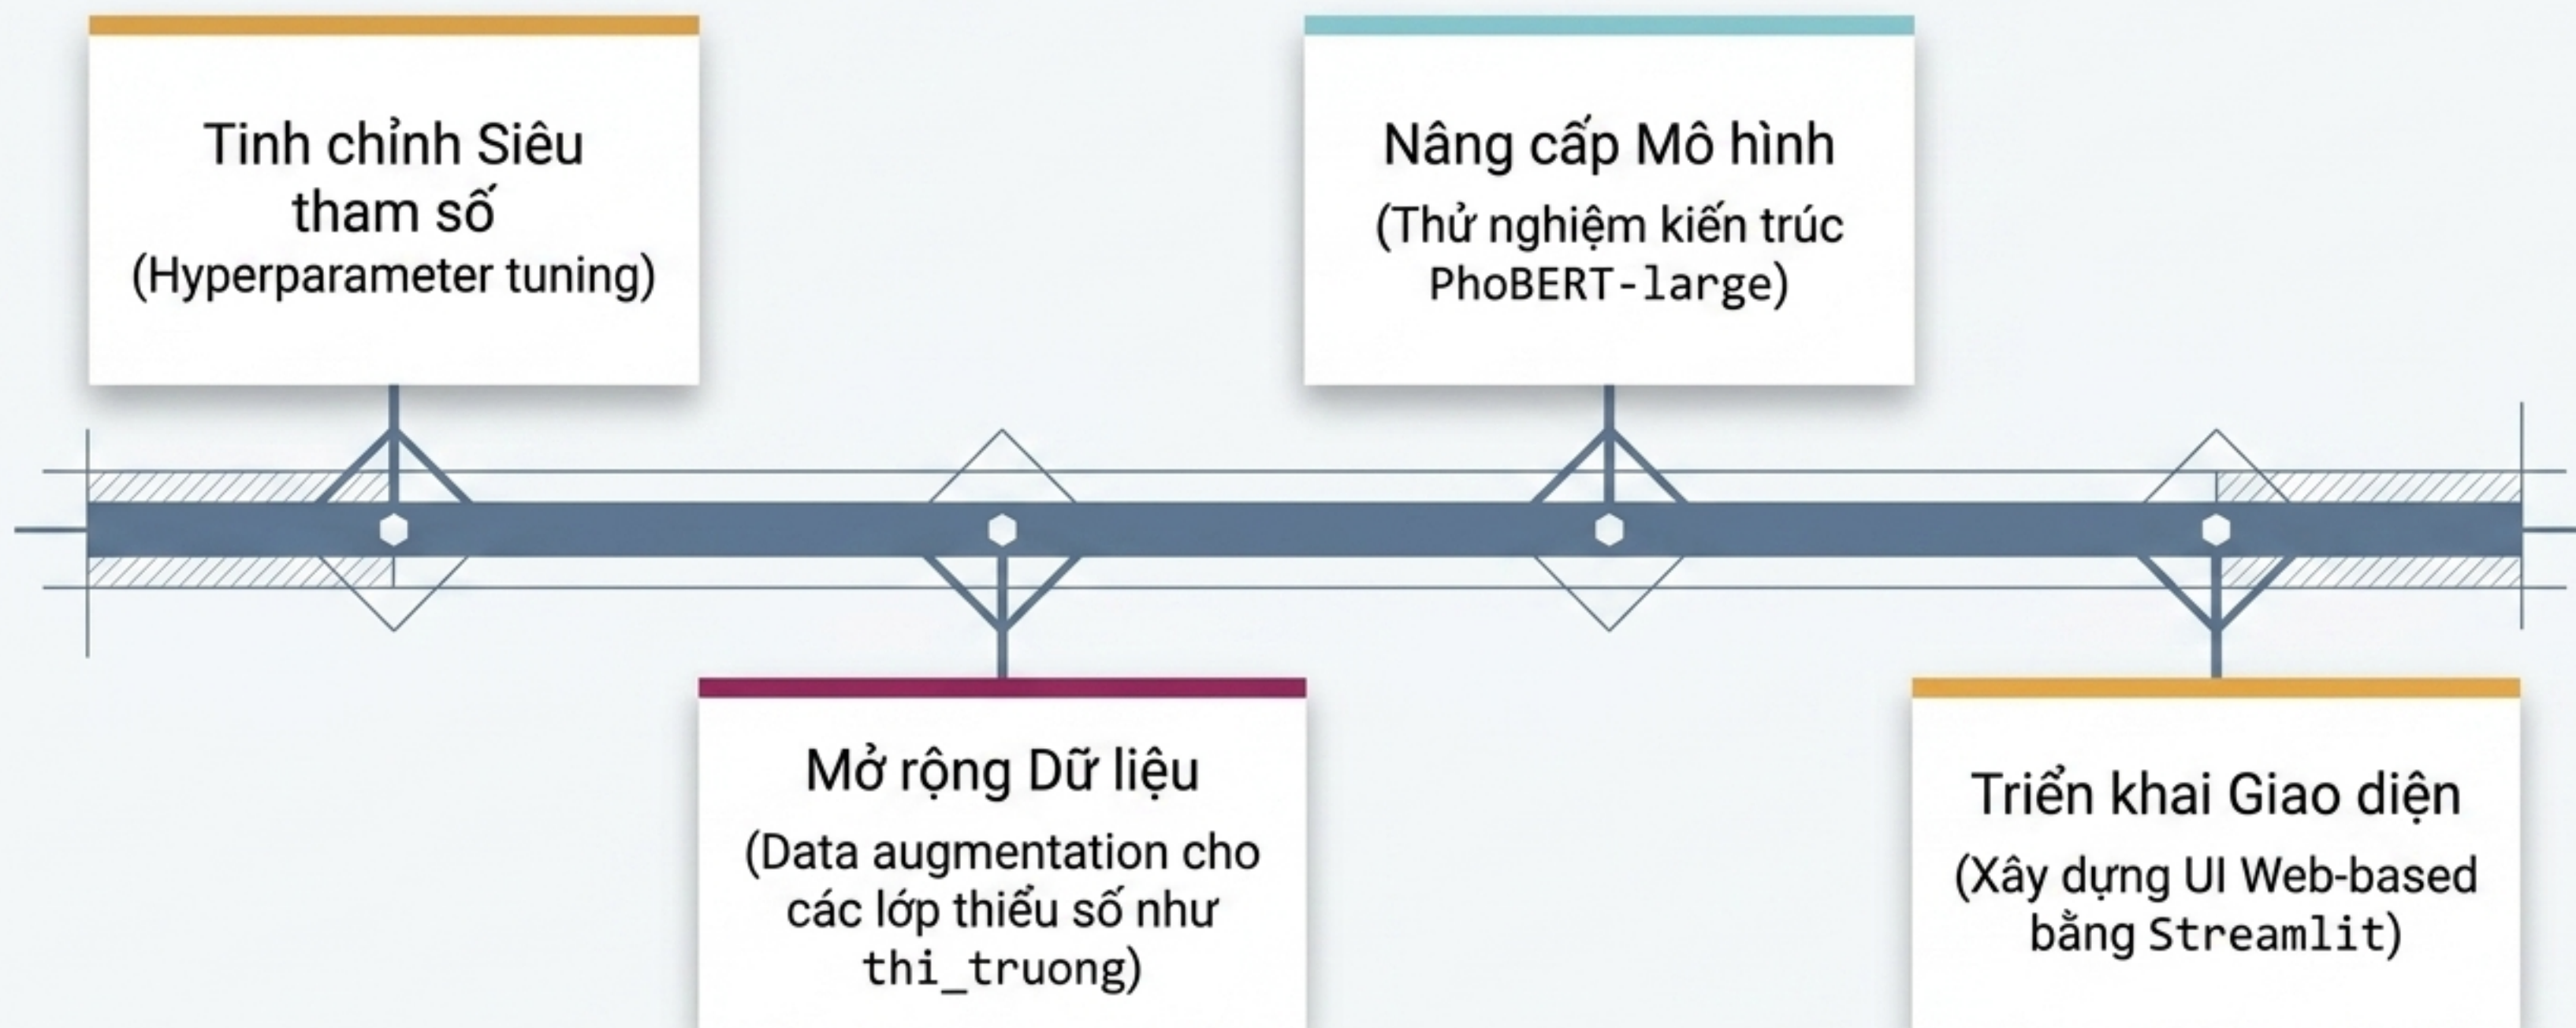
Phân tích Điểm mù & Thách thức

Điểm mù 1: Nhầm lẫn Ngữ nghĩa	
Category: thoi_su (Thời sự)	
Vấn đề: Recall thấp ở mức 0.62.	
Nguyên nhân: Sự chồng chéo chủ đề (tin thời sự thường bao hàm cả kinh tế, xã hội).	


Điểm mù 2: Thiếu hụt Dữ liệu	
Category: thi_truong (Thị trường)	
Vấn đề: Mẫu dữ liệu quá nhỏ (Support = 8).	
Hậu quả: Mô hình không đủ dữ liệu để hội tụ đặc trưng riêng biệt.	



Lộ trình Phát triển (Future Work)



Kỷ nguyên mới của NLP Tiếng Việt



1. Sức mạnh của Baselines

Machine Learning truyền thống (đặc biệt là SVM) vẫn cung cấp nền tảng vững chắc và tốc độ cao.

2. Sự Thống trị của Transformer

PhoBERT cải thiện đáng kể khả năng nắm bắt ngữ cảnh phức tạp của Tiếng Việt.

3. Giá trị Thực tiễn

Việc kết hợp Classification, Semantic Search (FAISS), và Local LLMs (Ollama) tạo ra một hệ thống RAG sẵn sàng triển khai cho doanh nghiệp.